

Transformer 모델

2. Transformer Model

■ 구글은 2017년 논문 "Attention Is All You Need"에서 트랜스포머(Transformer) 모델을 소개하며, 어텐션 메커니즘을 자연어 처리 분야에 혁신적으로 적용

Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer* Google Brain noam@google.com Niki Parmar* Google Research nikip@google.com Jakob Uszkoreit* Google Research usz@google.com

Llion Jones* Google Research llion@google.com Aidan N. Gomez* †
University of Toronto
aidan@cs.toronto.edu

Łukasz Kaiser* Google Brain lukaszkaiser@google.com

Illia Polosukhin* †
illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.0 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature.



지배적인 시퀀스 변환 모델은 복잡한 순환 신경망(RNN)이나 합성곱 신경망(CNN)을 기반으로 하며, 인코더와 디코더를 포함하고 있습니다. 최고의 성능을 보이는 모델들은 또한 인코더와 디코더를 어텐션 메커니즘을 통해 연결합니다. 우리는 어텐션 메커니즘만을 사용하는 간단한 네트워크 아키텍처인 Transformer를 제안하며, 순환과 합성곱을 완전히 없앴습니다. 두 가지 기계 번역 작업에 대한 실험에서 이 모델이 품질 면에서 우수하며, 병렬화가 더 잘 되고 훈련 시간이 크게 단축됨을 보여주었습니다.



어텐션 구조(Attention Architecture)

2. Transformer Model

- 그림의 각 픽셀이 개별 단어를 나타내고,
- 각 픽셀은 아라비아 수자 '7', 각 단어는 ["king", "queen", "prince", "princess", "man", "woman", "child"] 문장을 나타내며,
- 아라비아 수자 7은 각 픽셀의 밝기(중요도)를 차별하여 attention (Attention is all you need)



dneen woman child queen prince princess man

Image (pixel)

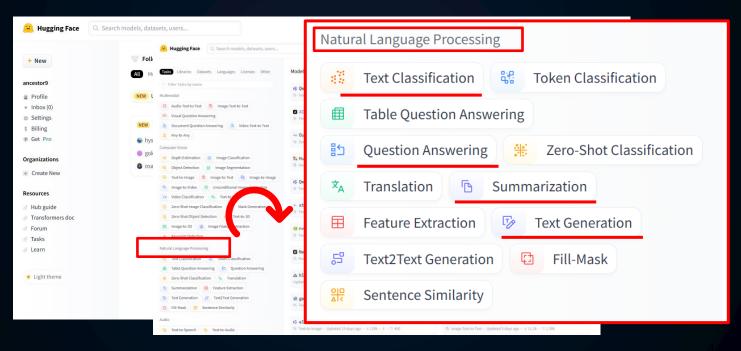
Text (word)



Hugging Face

2. Transformer Model

2016년에 설립된 AI 회사로, 처음에는 대화형 챗봇을 만드는 것에서 시작했지만, 현재는 NLP 모델과 도구의 오픈소스 플랫폼으로 발전하여 AI와 NLP 기술을 누구나 쉽게 사용할 수 있도록 만들 수 있는 플랫폼





2. Transformer Model



- ❖ 질의용답 (Question Answering): https://huggingface.co/deepset/roberta-base-squad2
- ❖ 문서분류 (Text Classification):

https://huggingface.co/tasks/zero-shot-classification

https://huggingface.co/yiyanghkust/finbert-tone

❖ 문서요약 (Document Summarization): https://huggingface.co/facebook/bart-large-cnn

❖ 문서생성 (Text Generation): https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct



챗봇

2. Transformer Model



Hugging Face

https://huggingface.co > chat :

HuggingChat - Hugging Face

Making the community's best Al **chat** models available to everyone. New Llama 3.3 70B is now available! Try it out! Current Model. Qwen/Qwen2.5-72B-Instruct.

Assistants

HuggingChat. Making the community's best AI chat ...

Models

Making the community's best AI chat models available to

Hugging Chat

Org profile for Hugging Chat on Hugging Face, the Al ...

Settings

Hugging Chat making the community's best Al chat ...

Qwen/Qwen2.5-Coder-32B ...

Making the community's best AI chat models available to

huggingface.co 검색결과 더보기 »



https://huggingface.co/chat/

